

MÓDULO 2 · CLASE 3

Métodos Estadísticos Avanzados

Regresión lineal · Regresión logística · Evaluación de modelos

Walter J. Méndez · UTEPSA / Khipus.ai

PREGUNTA ANCLA

**¿Cuánto va a ganar
un programador con
5 años de experiencia?**

Se responde mal en una línea. Bien, en una hora.

La misma pregunta, a otra cosa

2

La clase pasada

Le preguntamos a una diferencia entre dos grupos: ¿es real, o tuve suerte? Aprendimos a leer un p-valor.

estadística inferencial

3

Hoy

Le hacemos la misma pregunta a la pendiente de una recta. Y sumamos una nueva: ¿cuánto se equivoca?

regresión

El salto de hoy: pasar de "¿existe esta relación?" a "¿me sirve para predecir?".

Cuatro bloques hasta la respuesta

1

Ajustar una recta a los datos



2

Medir cuánto se equivoca



3

Agregar variables y arrepentirse



4

Cambiar la pregunta a sí/no

El bloque 2 es el que casi ningún curso enseña, y es el que te va a hacer valioso: cualquiera corre un `.fit()`, muy pocos saben cuánto vale el resultado.

Una recta que resume una nube



Los datos

Cada punto es un programador real de la encuesta del sábado pasado.

1 punto = 1 encuestado



La recta

Una sola línea que pasa lo más cerca posible de todos a la vez.

el modelo



La predicción

Estimar un caso que no está en la tabla. Por ejemplo: vos, con 5 años.

para qué sirve

El clásico de los libros es el precio de una casa según su tamaño. El nuestro es tu sueldo según tu experiencia: mismo método, otra historia.

La ecuación, y qué es cada cosa

$$\text{sueldo} = \beta_0 + \beta_1 \cdot \text{años}$$



β_0 · el intercepto

El punto turquesa: el sueldo que la recta predice con cero años.

β_1 · el coeficiente

La inclinación: cuánto sube el sueldo por CADA año más.

Casi nunca significa lo que parece

β_0 es el sueldo que la recta predice para alguien con CERO años de experiencia. En un rato vas a calcular ese número sobre el archivo real — y vas a tener que decidir si te lo creés.

0 años: se puede leer

Un recién egresado existe. El número significa algo, aunque sea discutible.

-5 años: no existe

La fórmula te contesta igual. Eso ya no es predecir: es inventar.

extrapolación

Un modelo solo vale dentro del rango de datos con el que lo ajustaste.

El residuo: lo que el modelo NO explica



$$\text{residuo} = \text{sueldo real} - \text{sueldo predicho}$$

Positivo

Está por encima.

Negativo

Gana menos.

Cero

Le pegó justo.

Tres formas de resumir los residuos

A

MAE

El error promedio, en dólares de sueldo. Sin signo. El más fácil de explicarle a un jefe.

`mean_absolute_error`

S

MSE

Eleva cada error al cuadrado: castiga los errores grandes. Pero queda en dólares AL CUADRADO.

`ilegible`

R

RMSE

La raíz del MSE: vuelve a dólares. Es el que se reporta, y el que vas a usar hoy.

`el importante`

El capítulo del curso lo dice sin vueltas: usá el RMSE como métrica principal.

El tamaño típico de tu error

"Mi modelo se equivoca, típicamente, en _____ dólares." Si no podés completar esa frase con un número, todavía no sabés si tu modelo sirve.

01

Predecís sueldos → el RMSE está en dólares.

02

Predecís minutos de entrega → el RMSE está en minutos.

03

Compará el RMSE contra el promedio de lo que predecís.


04

Si el error típico se parece al valor típico: el modelo no sirve.

¿Cuánto explica realmente tu modelo?

R^2 cerca de 1


sueldo ↑



la nube abraza la recta

R^2 cerca de 0

sueldo ↑



la recta apenas resume

¿Cuánto de tu sueldo te parece que explica la experiencia, ella sola? Guardate el número: en un rato lo calcularás.

Que exista no quiere decir que sirva

?

¿Existe la relación?

¿La experiencia tiene algo que ver con el sueldo? La responde el p-valor de la pendiente: la pregunta del sábado pasado, aplicada a β_1 .

p-valor · alfa = 0,05

!

¿Me sirve para predecir?

¿Puedo estimar TU sueldo con esto? La responden el RMSE y el R^2 . Es una pregunta completamente distinta.

RMSE · R^2

Pueden tener respuestas opuestas: una relación real y perfectamente inútil. Lo vas a ver en el notebook.

Los cuatro números de la tabla

`modelo.summary()`

01

Intercept → coef · es β_0 , dónde arranca la recta

02

experiencia → coef · es β_1 , cuánto sube por año

03

experiencia → $P>|t|$ · es el p-valor del sábado pasado

04

R-squared · cuánto explica el modelo (arriba)

La tabla trae veinte números más. Hoy te importan estos cuatro: tres en la tabla de abajo, uno arriba.

LA IDEA DEL DÍA


Estadísticamente significativo no quiere decir útil

*American Statistical Association, 2016 — principio 5:
"un p-valor no mide el tamaño de un efecto ni la importancia de un resultado"*


Mismo R^2 . Cuatro realidades distintas




Una relación lineal de verdad.



Es una curva, no una recta.



Un dato mal cargado tuerce todo.



Un punto manda sobre los demás.

Nunca creas un número de regresión sin haber mirado el gráfico. Los cuatro dan $R^2 = 0,67$ y exactamente la misma recta.

Cuando agregar variables empeora

$$\text{salario} = \beta_0 + \beta_1 \cdot \text{experiencia} + \beta_2 \cdot \text{exp_laboral} + \beta_3 \cdot \text{anios_codigo}$$

los nombres tal cual salen en el notebook de la práctica



Colinealidad

Las tres miden casi lo mismo: cuánto hace que programás. El modelo no sabe a cuál darle el crédito.

VIF > 5 preocupa



La consecuencia

Los p-valores se inflan. Vas a ver a la variable estrella apagarse en vivo.

lo vas a ver en vivo

Ojo: el R^2 sube SIEMPRE que agregás variables, aunque sean inútiles. Nunca lo uses para decidir.

Cuando la respuesta es sí o no

misma tabla, otra pregunta: ¿esta persona vive en EEUU?

$P(\text{vive en EEUU})$


1

El problema de la recta

Predice probabilidades negativas o mayores que 1. Eso no existe.

La solución: la sigmoide

La aplasta en una curva en S que nunca sale del 0 a 1.



Lineal vs. logística



Regresión lineal

Predice un NÚMERO.

Hoy: ¿cuánto va a ganar?

Otros: ¿cuánto cuesta?

Forma: una recta.

Se evalúa con RMSE y R^2 .

En Python: `ols` / `LinearRegression`.



Regresión logística

Predice una PROBABILIDAD de sí/no.

Hoy: ¿vive en EEUU?

Otros: ¿va a pagar?

Forma: una curva en S.

Se evalúa con exactitud.

En Python: `logit` / `LogisticRegression`.

AHORA SÍ, AL CÓDIGO

60 minutos de notebook

- Predecí antes de ejecutar. Sin eso es una demo; con eso es un descubrimiento.
- Si algo no corre, pegá el error en el chat. Hoy hay uno preparado a propósito.
- El dataset viene sucio, como en la vida real. Es contenido, no un problema.

03a_Metodos_Estadisticos_Avanzados_Practica_Guiada_Mini.ipynb